

ERINNERUNG:

- $X = \mathbb{R}^n$ SAMPLES, $y \in \mathbb{R}, \{0, -1, k\}$ labels
 $Z = X \times Y$
- \mathcal{D} WAHRSCHEINLICHKEITS VERTEILUNG AUF $X \times Y$.
- \mathcal{H} HYPOTHESIS SPACE, RAUM DER ZU BETRACHTENDEN FUNKTIONEN.
- $S \in Z^m$ TRAININGSDATEN
- $\ell: \mathcal{H} \times Z \rightarrow \mathbb{R}_+$ LOSS FUNCTION

WOBEI $\ell(h, -): Z \rightarrow \mathbb{R}_+$ MESSBAR / INTEGRIERBAR $\forall h \in \mathcal{H}$.

BSP: • 0-1 loss $\ell_{0-1}(h, (x, y)) = \begin{cases} 1 & h(x) \neq y \\ 0 & \text{sonst} \end{cases}$

• Square loss $\ell_{\text{sq}}(h, (x, y)) = (h(x) - y)^2$

• $L_0: \mathcal{H} \rightarrow \mathbb{R}_+$ RISK FUNCTION
 $h \mapsto \mathbb{E}_{z \sim \mathcal{D}} (\ell(h, z))$

• $L_{-}(-): Z^m \times \mathcal{H} \rightarrow \mathbb{R}_+$ EMPIRISCHER RISK.
 $(S, h) \mapsto L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, z_i)$

WOBEI $S = (z_1, \dots, z_m)$

i.i.d. BETRACHTEN PRODUKTMASS AUF Z^m

(2)

EMPIRICAL RISK MINIMIZATION

~~Finde $h \in H$ s.d. L~~

Sei $S \in Z^m$. Finde $h \in H$ s.d. $L_S(h)$ minimiert wird.

Wir untersuchen, unter welchen Bedingungen EMK zu einer guten Hypothese führt, also $L_D(h)$ klein

Dazu:

• Realisierbarkeit: $\exists h^* \in H$ s.d. $L_D(h^*) = 0$

$\Rightarrow L_S(h^*) = 0$ F.S.

\Rightarrow ~~Es~~ Für $h_S \in \argmin_{h \in H} L_S(h)$ gilt $L_S(h_S) = 0$ F.S.

• Es gibt einen Lern Algorithmus, der h_S bestimmt.

• Betrachten im folgenden Klassifikation $y = \{0,1\}$ und $L = L_{0,1}$

Satz: Sei $|H| < \infty$, $\varepsilon, \delta \in (0,1)$, $m \geq \frac{1}{\varepsilon} \log\left(\frac{|H|}{\delta}\right)$

Sei D W-Vert auf Z s.d. Realisierbarkeit erfüllt ist für H .

Dann gilt:

Mit W'kt $\geq 1 - \delta$ Bzgl $S \in Z^m$ ist

$L_D(h_S) \leq \varepsilon$ für jedes $h_S \in \argmin_{h \in H} L_S(h)$

3

MIT ANDEREN WORTEN:

FÜR n GROSS GENUG FÜHRT ERN ZU EINER HYPOTHESE,
DEREN OBERE ^{FEHLER}SCHRANKE GEGEBEN IST DURCH ε .

$$L_0(h_s) \leq \varepsilon.$$

BEWEIS: BETRACHTEN DIE FV. UND $h_s = \arg \min_{h \in H} L_0(h)$

$$Z^n \longrightarrow \mathbb{R}_+$$

$$s \longmapsto L_0(h_s)$$

WOLLEN DAS n -MASS DER MENGE $\{s \in Z^n \mid L_0(h_s) \leq \varepsilon\}$
ABSCHÄTZEN.

SEI $H_\varepsilon = \{h \in H \mid L_0(h) > \varepsilon\}$ "SCHLECHTE" HYPOTHESEN

$$M = \{s \in Z^n \mid \exists h \in H_\varepsilon, L_s(h) = 0\} \text{ "SCHLECHTE" TRAININGS DATEN.}$$

WEGEN REALISABILITÄT GILT:

$$L_s(h_s) = 0 \Rightarrow L_0(h_s) > \varepsilon \Leftrightarrow \exists h \in H_\varepsilon \text{ mit } L_s(h) = 0$$

$$\text{Also ist } \{s \in Z^n \mid L_0(h_s) > \varepsilon\} \subseteq M$$

$$\text{WEITER } M = \bigcup_{h \in H_\varepsilon} \{s \in Z^n \mid L_s(h) = 0\}$$

④

Also:

$$D^m(L_D(h_S) > \varepsilon) \leq D^m(H) \leq \sum_{|H|} D^m(L_S(h) = 0) \quad (*)$$

Sei $h \in H_S$ fest.

Setzt gilt $L_S(h) = 0 \Leftrightarrow \ell(h, \pi_i) = 0 \quad \forall i = 1, \dots, m \quad (S = (\pi_1, \dots, \pi_m))$

Somit:

$$D^m(L_S(h) = 0) = D^m(\{S \in \mathcal{Z}^m \mid \ell(h, \pi_i) = 0 \forall i\})$$

$$\stackrel{i.i.d.}{=} \frac{1}{2^m} D(\ell(h, \pi_i) = 0)$$

Wir haben $D(\ell(h, \pi_i) \neq 0) = D(\ell((x, y) \mid h(x) \neq y))$

$$= L_D(h) \quad (= \int \mathbb{1}_{h(x) \neq y})$$

Also

$$D(\ell(h, \pi_i) = 0) = 1 - L_D(h) \leq 1 - \varepsilon$$

Da $h \in H_S \Rightarrow L_D(h) > \varepsilon$

$$\Rightarrow D^m(L_D(h_S) > \varepsilon) \leq |H_S| (1 - \varepsilon)^m \leq |H| (1 - \varepsilon)^m$$

Wir haben $1 - \varepsilon \leq e^{-\varepsilon}$

$$\Rightarrow D^m(L_D(h_S) > \varepsilon) \leq |H| e^{-\varepsilon m}$$

5

FÜR $m \geq \frac{1}{\varepsilon} \log \left(\frac{|H|}{\delta} \right)$ GILT ALSO

$$\mathbb{P}^m (L_D(h) > \varepsilon) \leq \delta \Rightarrow \mathbb{P}^m (L_D(h) \leq \varepsilon) \geq 1 - \delta$$

□

PROBABLY APPROXIMATELY CORRECT LEARNING

DEF: (PAC - LEARNABILITY)

EINE KLASSE H HEISST PAC - LERNBAR (BZGL. $Z = X \times Y$
(LOSS Fkt.))

FALLS ES EINE FUNKTION $m_H : (0,1)^2 \rightarrow \mathbb{N}$

UND EIN LERN ALGORITHMUS EXISTIERT, S.D. FOLGENDES GILT:

- $\forall \varepsilon, \delta \in (0,1)$
- \forall DISTR. D AUF Z , S.D. H REALISIERUNG BZGL. D ERFÜLLT.

i.i.d.

WENN DER ALGORITHMUS MIT TRAININGDATEN DER GRÖSSE

$m \geq m_H(\varepsilon, \delta)$ TRAINIERT WIRD,

DANN GIBT DER ALGORITHMUS EINE HYPO h ZURÜCK

S.D. $L_D(h) \leq \varepsilon$ MIT W'KT $\geq 1 - \delta$ (IN SAMPLES TRAINING)

BSP: H ENCL. \rightarrow ALSO ERM

PARAMETER IN PAC-LEARNING

- ϵ ACCURACY PARAM, WIE GENAU IST DER LERNER
- δ CONFIDENCE PARAM: WIE WAHRSCHENLICH
- m_H "SAMPLE COMPLEXITY"

DEF: DIE SAMPLE COMPLEXITY UM MIT H ZU LERNEN IST DAS MINIMUM DER FKT. $m_H(\epsilon, \delta)$ S.D. H PAC-LERNBAR IST.

KORO: JEDE ENDL. KLASSE H IST PAC-LERNBAR MIT SAMPLE COMPLEXITY $m_H(\epsilon, \delta) \leq \left\lceil \frac{\log(|H|)}{\epsilon} \right\rceil$

OHNE REALISIERBARKEIT:

ERINNERUNG: $h^* \in H$ S.D. $L_D(h) = 0$

FÜR KLASSEFICATION IMPLIZIERT DIES EINE FIKTIVE RELATION ZU SAMPLES UND LABELS

DIES MUSS NICHT IMMER GELTEN SEIN.

STATTOBERST SCHÄTZEN WIRD MIT DEM MINIMUM AB.

Def: (AGNOSTIC PAC-LEARNING)

\mathcal{H} ist AGNOSTIC PAC-LEARNABLE bzgl. f, l

FALLS $m_{\mathcal{H}} : (0,1)^2 \rightarrow \mathbb{N}$ EXISTIERT \rightarrow WIRD LERN ALGO ES S.N.

- $\forall (\epsilon, \delta) \in (0,1)$
- $\forall D$

WENN DER ALG. AUF $m_{\mathcal{H}}(\epsilon, \delta)$ IID STÄRKES
LERNT, ENDET $h \in \mathcal{H}$ ZURÜCKGEHT S.D.,

$$L_D(h) \leq \min_{h' \in \mathcal{H}} L_D(h') + \epsilon \quad \text{MIT WKT} \geq 1 - \delta$$

Beim. OFFENBARE VERMUT. DES PAC-LEARNINGS

Beisp. EINES MIN. PAC FÜR KLASZIFIKATION.

D VERF. MIT $X \in \{0,1\}$

DANN IST

$$f_D(x) = \begin{cases} 1 & \text{FALLS } P(y=1|x) \geq \frac{1}{2} \\ 0 & \text{SONST} \end{cases}$$

EINE OPTIMALE HYPOTHESE

ES: FOLGT DIES

WOHIN JETZT FOLGEN, DASS EMPL. ^{HYPO} KUTSSEN

AGNOSTISCH PAC-LEARNER SIND.

DEF:

(ϵ -REPRESENTATIVE SAMPLE)

$S \subseteq Z^m$ TRAININGSDATEN SIND ϵ -REPRÄSENTATIV

(BZGL Z, H, ℓ, D) FALS

$$\forall h \in H, |L_S(h) - L_P(h)| \leq \epsilon$$

LEMMA: S $\frac{\epsilon}{2}$ -REP. DANN GILT FÜR $h_S = \arg \min_{h \in H} L_S(h)$

$$L_D(h_S) \leq \min_{h \in H} L_P(h) + \epsilon$$

BZW: $L_D(h_S) \leq L_S(h_S) + \frac{\epsilon}{2} \leq L_S(h) + \frac{\epsilon}{2} \leq L_D(h) + \frac{\epsilon}{2} + \frac{\epsilon}{2}$

D

DAS IMPLIZIERT: ~~DA~~ ^{AGN} DAMIT BZW PAC-LEARNER IST

ZEIGT ES, DASS MIT WEL NIMMT $n \geq \frac{1}{\epsilon^2}$, S ϵ -REP IST

2

Def: \mathcal{H} hat die uniform convergence Eig.
(siehe 7.1)

Es sei $\mathcal{H}^u, (0,1)^2 \rightarrow \mathbb{R}$ s.p. $\forall \varepsilon, \delta \in (0,1)$
 $\exists N$ mit

Gmt: für $S \in \mathcal{H}^u$ mit $m \geq m_{\varepsilon, \delta}$

dann ist S mit $\forall \varepsilon$ ε -pp

Es ist \mathcal{H} ist \mathcal{H}^u \mathcal{H} \mathcal{H}^u \mathcal{H}

uniform convergence existiert

Satz: $|\mathcal{H}| < \infty$ dann ist \mathcal{H} \mathcal{H}^u \mathcal{H} \mathcal{H}^u

Wir haben $|\mathcal{H}| < \infty \Rightarrow \mathcal{H}$ hat \mathcal{H}^u Eig.

Idee wie vorher.

Wir schreiben

$$D^u(|S| \mathcal{H} \in \mathcal{H}, \mathcal{H}_S(\mathcal{H}) - \mathcal{L}_D(\mathcal{H})| > \varepsilon) \quad \text{AB}$$

Es gilt

$$D^u(|S| \mathcal{H} \in \mathcal{H}, \mathcal{H}_S(\mathcal{H}) - \mathcal{L}_D(\mathcal{H})| > \varepsilon) \leq \sum_{\mathcal{H} \in \mathcal{H}} D^u(\mathcal{H}_S(\mathcal{H}) - \mathcal{L}_D(\mathcal{H})| > \varepsilon)$$

INTUITION:

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{n} \sum (x_i - \mu) \geq \epsilon\right) = 0$$

PROBLEM: nur logarithmische Verteilung

LEMMA: (HOEFFDING'S UNGL.)

$$\theta_1, \dots, \theta_n \text{ i.i.d. H.V. } \forall i: E(\theta_i) = \mu$$

$$P(a \leq \theta_i \leq b) = 1 \quad \text{DANN GILT } \forall \epsilon > 0$$

$$P\left(\left|\frac{1}{n} \sum \theta_i - \mu\right| > \epsilon\right) \leq 2e^{-2n\epsilon^2/(b-a)^2}$$

DAMIT KÖNNEN WIR GUT ABGESCHÄTZEN

(*)

$$\theta_i = (h, z_i)$$

$$\text{ANW } h \in \mathcal{H}$$

$$D^n(\{h \in \mathcal{H} : |L_S(h) - L_D(h)| > \epsilon\})$$

$$\leq \sum_{h \in \mathcal{H}} P^n(|L_S(h) - L_D(h)| > \epsilon) \leq 2|\mathcal{H}|e^{-2n\epsilon^2}$$

$$\Rightarrow n \geq \frac{\log(2|\mathcal{H}|/\delta)}{2\epsilon^2} \Rightarrow D^n(h) \leq \delta$$

11

WIE HABEN GEZEIGT.

88 H ENPL. , $C: H \times \mathbb{R} \rightarrow [0,1]$ WASS FÜR

DANN ERFÜLLT H DIE UNF. 6.

Mit STUMPF COMPLEX $m_H^u(\varepsilon, \delta) \leq \int \frac{\log(2|H|/\delta)}{2\varepsilon^2} \Bigg]$

WEITERHIN GELT H IST ABN. PAC. KRNNBTR

Mit ERM ALGO. MIT STUMPF COMPLEX

$$m_H(\varepsilon, \delta) \leq m_H^u\left(\frac{\varepsilon}{2}, \delta\right) \leq \int \frac{2 \log(2|H|/\delta)}{\varepsilon^2} \Bigg]$$