

LEASURE 3:

RECHN AGNOSTIC PAC - LEARNING:

EINE HYPOTHESEN KLASSE/RAUM \mathcal{H} IST AGNOSTISCH - PAC - LERNBAR

BZGL \mathcal{Z} - UND LOSS $\ell: \mathcal{H} \times \mathcal{Z} \rightarrow \mathbb{R}_+$ FALLS EINE FKT

$m_{\mathcal{H}}: (0,1)^2 \rightarrow \mathbb{N}$ UND EIN LERN ALGORITHMUS EX. S.D.

- $\forall \epsilon, \delta \in (0,1)$
- \forall DISTR. D AUF \mathcal{Z}
- $m \geq m_{\mathcal{H}}(\epsilon, \delta)$
- $A: \mathcal{Z}^m \rightarrow \mathcal{Y}^{\mathcal{X}}$

MIT WAHRSCHEINLICHKEIT $\geq 1 - \delta$ $L_D(A(S)) \leq \min_{h \in \mathcal{H}} L_D(h) + \epsilon$

HABEN GESEHEN: FÜR KLASSIFIKATION, FALLS D REANBIERBAR IST

SIND ENDEZ KLASSEN \mathcal{H} LERNBAR, BAYES OPTIMALE KLASSE

$m_{\mathcal{H}}$ IST KOMPLEXITÄT

DEF: (ϵ -REPRÄSENTATIVES SAMPLE)

$S \in \mathcal{Z}^m$ IST ϵ -REP (BZGL \mathcal{H}, ℓ, D) FALLS

$$\forall h \in \mathcal{H}, |L_S(h) - L_D(h)| \leq \epsilon$$

ALSO: S IST ϵ -REP FALLS FÜR \mathcal{H} DER EMPIRISCHE FEHLER NICHT ZU VIEL VON DEM ECHTEN FEHLER IST.

LEMMA: S ϵ -REP; $h_S \in \arg\min_{h \in \mathcal{H}} L_S(h)$

$$\Rightarrow L_D(h_S) \leq \min_{h \in \mathcal{H}} L_D(h) + \epsilon$$

D.H.: MM zu zeigen, dass ERM-DALE äquivalent PAC-lernbar ist
genügt es ϵ -REP zu zeigen mit Wert $\geq 1-\delta$

Def: \mathcal{H} hat uniform convergence prop falls

$$m_{\mathcal{H}}^{\text{uc}}: (0,1)^+ \rightarrow \mathbb{N} \text{ ex.}$$

- S.P.
- $\forall \epsilon, \delta \in (0,1)$
 - $\exists m_{\mathcal{H}}^{\text{uc}}(\epsilon, \delta)$

Falls $S \in \mathcal{Z}^m$, $m \geq m_{\mathcal{H}}^{\text{uc}}(\epsilon, \delta)$ dann S hat ϵ -REP mit Wert $\geq 1-\delta$

Coro: \mathcal{H} hat MC mit $m_{\mathcal{H}}^{\text{uc}}$ dann ist \mathcal{H} AGN. PAC-lernbar

$$\text{mit } m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{\text{uc}}(\frac{\epsilon}{2}, \delta)$$

In dem Fall ist $\text{ERM}_{\mathcal{H}}$ ein AGN. PAC-Lerner

Satz: endl. Klassen sind AGN. PAC-lernbar.

Bew: zeigen MC für endl. \mathcal{H} .

Seien $\epsilon, \delta \in (0,1)$ fix. wollen zeigen:

$$\mathcal{D}^m(|S| \geq k \in \mathcal{H}, |L_S(h) - L_D(h)| > \epsilon) < \delta$$

es gilt

$$\mathcal{D}^m(|S| \geq k \in \mathcal{H}, |L_S(h) - L_D(h)| > \epsilon) \leq \sum_{k \in \mathcal{H}} \mathcal{D}^m(|S| \geq k, |L_S(h) - L_D(h)| > \epsilon)$$

jetzt schätzen wir die Summanden ab

wir brauchen eine quantitative Version des GdGZ:

Lemma: (Hoeffding's Ungleichung)

$\theta_1, \dots, \theta_m$ i.i.d. R.V., $E(\theta_i) = \mu$; $P(a \leq \theta_i \leq b) = 1$ für $a, b \in \mathbb{R}$

Dann gilt $\forall \epsilon > 0$:

$$P\left(\left|\frac{1}{m} \sum_{i=1}^m \theta_i - \mu\right| > \epsilon\right) \leq 2e^{-\frac{2m\epsilon^2}{(b-a)^2}}$$

NEHMEN GIBT AN $h \in [0,1]$ UND SETZEN $\theta_i = \ell(h, z_i)$ DANN FOLGT

$$D^m \left(\{s \mid \exists h \in H, |L_s(h) - L_0(h)| > \varepsilon \} \right) \leq 2|H| e^{-\frac{2m\varepsilon^2}{(b-a)^2}}$$

DANN GILT FÜR $m > \frac{\log(2|H|/\delta)}{2\varepsilon^2}$

$$D^m \left(\{s \mid \exists h \in H, |L_s(h) - L_0(h)| > \varepsilon \} \right) \leq \delta$$

□

Bias - Complexity - Tradeoff:

IDEE: UM OVERFITTING ZU VERMEIDEN BESCHRÄNKEN WIR H .

⇒ HABEN EINE FORM VON PRIOR KNOWLEDGE!

BSP VON PRIOR KNOWLEDGE:

- WISSEN ÜBER D z.B. D NORMALVERTEILT MIT PARAM θ
- BEAUBERBARKEIT / KLEINES h
- WISSEN KONVERGES f \Rightarrow BEAUBERBAR ABER OVERFITTING

FRAGE: IST PRIOR KNOWLEDGE NOTWENDIG?

EX. EIN UNIVERSELLER LERNALGO?

SATZ: (NO - FREE - LUNCH)

SEI A LERN ALGO FÜR BIN. KLAS. PROBL. 0-1-LOSS.

SEI $m \leq \frac{|X|}{2}$. DANN EX. D AUF $X \times \{0,1\}$ S.D.

1. $\exists f: X \rightarrow \{0,1\}$ MIT $L_D(f) = 0$

2. $L_D(A(S)) \geq \frac{1}{8}$ MIT $w_k \geq \frac{1}{2}$.

BEWEIS: $A: \mathbb{Z}^m \rightarrow (\mathbb{Z} \rightarrow [0,1])$

IDEA: Sei $C \subseteq X$ mit $|C| = 2^m$.

Sei $f: C \rightarrow [0,1]$.

DEF. VERST. \mathcal{D} auf $X \times [0,1]$ DIE UNIFORM AUF DEM BILD VON f IST.

ZEIGEN DASS WIR MIT SOLCHEN VERTEILUNGEN $L_0(A(S)) \geq \frac{1}{8}$

ABSCHÄTZEN KÖNNEN.

BEZUGSWEISE $|f_1, \dots, f_T| = |C \rightarrow [0,1]|$, $T = 2^m$

DEF FÜR f : $\mathcal{D}_i(x,y) = \begin{cases} \frac{1}{|C|} & f_i(x) = y \\ 0 & \text{SONST} \end{cases}$

WOLLEN ZEIGEN:

$$\max_i \mathbb{E}_{S \sim \mathcal{D}_i} L_0(A(S)) \geq \frac{1}{4} \quad (*)$$

MIT DER MARKOV UNGLEICHUNG

$$P(|X| \geq a) \geq \frac{1-a}{1-a} \quad a \in (0,1)$$

FOLGT:

$$\mathbb{P}^m \left(L_0(A(S)) \geq \frac{1}{8} \right) \geq \frac{\frac{1}{8}}{\frac{3}{4} + \frac{1}{8}} = \frac{1}{24} \quad \text{Zu zeigen: } \geq \frac{1}{8}$$

ES BLEIBT $(*)$ ZU ZEIGEN.

WIR BETRACHTEN ~~SE~~ TRAININGSDATEN AUS C .

ES GIBT $L = (2^m)^n$ MÖGLICHE SAMPLES AUS C !

$$S_1, \dots, S_L$$

FÜR f_i : SCHREIBE S_j^i FÜR DIE TRAININGSDATEN

$$S_j^i = (x_1^j, f_i(x_1^j), \dots, x_m^j, f_i(x_m^j))$$

WEGEN GLEICHVERTEILUNG AUF \dots

HABEN ALLE S_j^i GLEICHE WKT GESAMPLT zu WERDEN
BEGL \mathcal{D}_i^m

$$\text{DAHER GILT } \mathbb{E}_{S \sim \mathcal{D}_i^m} (L_{\mathcal{D}_i}(A(S))) = \frac{1}{L} \sum_{j=1}^L L_{\mathcal{D}_i}(A(S_j^i))$$

JETZT SCHÄTZEN WIR NACH i AB:

$$\begin{aligned} \max_i \mathbb{E}_{S \sim \mathcal{D}_i^m} L_{\mathcal{D}_i}(A(S)) &\geq \frac{1}{T} \sum_{i=1}^T \frac{1}{L} \sum_{j=1}^L L_{\mathcal{D}_i}(A(S_j^i)) \\ &\geq \min_j \frac{1}{T} \sum_{i=1}^T L_{\mathcal{D}_i}(A(S_j^i)) \end{aligned}$$

WIR SCHÄTZEN JETZT DIE SUMMANDEN ~~AB~~ $L_{\mathcal{D}_i}(A(S_j^i))$ AB.

Dazu: $S_j = (x_1^j, \dots, x_m^j) = (x_1, \dots, x_m)$

$$\text{SEIEN } v_1, \dots, v_p \in C \text{ s.d. } v_i \neq x_j \quad \forall i=1, \dots, p \\ j=1, \dots, m$$

$$\Rightarrow p \geq m \quad \text{oder} \quad |C| = 2m$$

1.6.7.5 GLT F4.2 $h: C \rightarrow [0, 1]$

$$L_{D_i}(h) = \frac{1}{2m} \sum_{x \in C} \frac{1}{h(x) \neq f_i(x)}$$

$$\geq \frac{1}{2p} \sum_{r=1}^p \frac{1}{h(v_r) \neq f_i(v_r)}$$